


UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
VALPARAÍSO - CHILE



**REPRODUCIBILITY OF COMPUTATIONAL ENVIRONMENTS
FOR SCIENTIFIC EXPERIMENTS USING-CONTAINER-BASED
VIRTUALIZATION**

MAXIMILIANO FEDERICO OSORIO BAÑADOS

TESIS PARA OPTAR LA GRADO DE
MAGÍSTER EN CIENCIAS DE LA INGENIERÍA INFORMÁTICA

DICIEMBRE 2018

Índice general

Índice general	II
Índice de figuras	IV
Índice de tablas	V
Índice de algoritmos	VI
1. Introducción	1
2. Estado del arte	4
2.1. Conservación de procedimiento científicos	4
2.2. Conservación de equipamiento	6
2.3. Docker	11
2.4. Web Semantica	17
2.5. Sistemas de paquetes y vulnerabilidades	19
3. Objetivos de trabajo	20
3.1. Problemas de investigación abierto	20
3.2. Hipótesis	21
3.3. Objetivos	21
3.4. Restricciones	22
4. Representación de ambiente de ejecución	23
4.1. Modelos semánticos	24
4.2. Anotador	25
5. Experimentación y evaluación	30
5.1. Experimentos computacionales	30
5.2. Conservación física	39
5.3. Conservación lógica	42
5.4. Resultados y discusión	45
6. Conclusiones y trabajo futuro	47
6.1. Main 1	47

Índice de figuras

2.1.	Dado que un contenedor comparte recursos, esto reduce significativamente el uso de almacenamiento en comparación a las máquinas virtuales. . . .	12
2.2.	Docker	13
2.3.	Las imágenes Docker con compuestas por capas. La última capa (a1886ebc75ae) es la única capa en modo escritura.	14
4.1.	Docker ontology.	25
5.1.	Dependencias de Pegasus. En azul: dependencias necesarias y especificadas en el sistema de paquetes. En verde: necesarias pero no especificadas en el sistema de paquetes. En naranjas: dependencias recomendadas	33
5.2.	Representación entregada por Pegasus del workflow SoyKB.	34
5.3.	Dependencias de SoyKb. En amarillo: software propio y en verde software de terceros	34
5.4.	Representación entregada por Pegasus del workflow Montage. Cada uno de los nodos es una operación y la leyenda indica el nombre de la operación.	35
5.5.	Los resultados obtenidos con el nuevo ambiente son iguales	36
5.6.	Pasos necesarios para el workflow internal extinction	36
5.7.	Pasos necesarios para el workflow internal extinction	37
5.8.	Dependencias de WINGS	38
5.9.	Figure caption.	39
5.10.	Los resultados obtenidos con el nuevo ambiente son iguales	40
5.11.	El sistema anotador permite recibir la información de la imagen, consultar los componentes de software a nuestra versión de Clair, obtener metadatos desde el manifiesto y almacenar la información en forma de triples en Apache Jena.	43
5.12.	The orange nodes are the differences between the images	46

Índice de tablas

5.1. Image appliances characteristics.	41
5.2. Uso de disco de las imágenes pegasus y dispel4py utilizando máquinas virtuales y containers	46

Índice de algoritmos

Capítulo 1

Introducción

Científicos han argumentado sobre la importancia de poder reproducir experimentos científicos debido a la necesidad de corroborar los resultados y conclusiones y a la necesidad de contribuir en el mismo trabajo.

Sin embargo, proceso de reproducibilidad puede ser tan complejo y costoso que ha sido referido como una tarea forense [1]. De hecho, estudios controversiales y escándalos han expuesto la necesidad de mejorar los procesos de reproducibilidad de las investigaciones. Algunos ejemplos son: casos clínicos [2], sondeos del área de psicología [3] o estudios en área de la computación [1].

La reproducibilidad del experimento es la capacidad de volver a ejecutar un experimento con o sin la introducción de cambios en él y la obtención de resultados que sean consistentes con los originales. La introducción de cambios permite evaluar diferentes características de ese experimento ya que los investigadores pueden modificarlo gradualmente, mejorando y reorientando los métodos y condiciones experimentales [4].

Para permitir la reproducibilidad del experimento es necesario proporcionar suficiente información sobre él mismo, permitiendo comprenderlo, evaluarlo y volver a construirlo. Normalmente, los experimentos se describen en flujos de trabajo científicos (representaciones que permiten gestionar cálculos a gran escala) que se ejecutan en sistemas informáticos distribuidos. Para permitir la reproducibilidad de estos flujos de trabajos científicos es necesario, en primer lugar, abordar un problema de conservación del flujo de trabajo. La conservación es un acto de proporcionar información compresible que describa el contexto original del experimento [?] y es por ello que los flujos de trabajo experimentales necesitan garantizar que haya suficiente información sobre los experimentos para que sea posible

construirlos nuevamente por un tercero, replicando sus resultados sin ninguna información adicional del autor original [5].

Para alcanzar la conservación la comunidad se ha enfocado en la conservación de las ejecuciones de workflow conservando los datos, código y la descripción, pero no dejando de lado la infraestructura subyacente (e.g, recursos computacionales y componentes de software). Existe otros enfoques que se han enfocado en conservar el ambiente computacional de un experimento como WICUS [6] o el proyecto TIMBUS ¹ [7] que describe los procesos de negocios y el software y el hardware subyacente.

Los autores en [6] identificaron dos enfoques para conservar el ambiente computacional de un experimento científico: la conservación física, en la que los objetos de investigación dentro del experimento se conservan en un entorno virtual (e.g., máquinas virtuales); y la conservación lógica, en la que se describen las principales capacidades de los recursos del ambiente computacional utilizando vocabularios semánticos para que el investigador pueda reproducir un entorno equivalente. Definieron un proceso para documentar la aplicación de flujo de trabajo y su sistema de gestión relacionado, así como sus dependencias.

Sin embargo, este proceso es realizado en forma manual, dejando trabajo restante para los científicos. Además, al igual que la mayoría de los trabajos dejan fuera del alcance la conservación física del entorno computacional del flujo de trabajo (basándose en la infraestructura elegida). Sin embargo, la conservación lógica y física es importante para lograr la reproducibilidad del experimento.

El problema de reproducibilidad no sólo sucede en la comunidad científica. Compañías IT también enfrenta problemas similares cuando ellos desean distribuir cualquier producto de software a múltiples servidores. Para resolver esto, compañías utilizan virtualización a nivel. Esta tecnología se refiere a una característica del Sistema Operativo (SO) en la que el kernel del SO permite la existencia de múltiples instancias aisladas de espacio de usuario llamadas máquinas virtuales o contenedores. Una de las tecnologías de virtualización más populares en la industria es Docker², que implementa la virtualización de software mediante la creación de versiones mínimas de un sistema operativo base (un contenedor). Los Docker Containers pueden ser vistos como máquinas virtuales ligeras que permiten el ensamblaje de un entorno computacional, incluyendo todas las dependencias necesarias, como bibliotecas, configuración, código y datos necesarios, entre otros.

¹<http://www.timbusproject.net/>

²<https://www.docker.com/>

Para reproducir experimentos científicos computacionales de otros investigadores, es obligatorio permitir que los científicos compartan estos experimentos o permitir que los ejecuten de nuevo ambiente computacional reproducido (el mismo o muy similar). De esta manera, un científico tendrá garantías de que el experimento que está ejecutando en el mismo entorno o similar desde el que fue creado. Por lo tanto, se necesita un procedimiento que garantice ambos requisitos: preservar los entornos tanto lógicos como físicos para volver a ejecutar los flujos de trabajo de datos con garantías de reproducibilidad. Para permitir esta reproducibilidad es necesario, por lo tanto, proporcionar una manera de describir primero los experimentos científicos y el entorno computacional en el que se ejecutó el experimento. La conservación lógica permite describir el entorno computacional en el que se ejecutó el experimento y la conservación física permite a los investigadores volver a ejecutar un experimento sin tener que ocuparse de la distribución física del a y sin tener que ocuparse de los problemas de dependencias.

Por lo tanto se una solución para mejorar la solución de conservación física y lógica mediante el uso de contenedores. Se propone en primer lugar utilizar las imágenes Docker como medio para preservar el entorno físico de un experimento. Se utiliza contenedores ya que son ligeros y, lo que es más importante, son más fáciles de describir automáticamente, por lo que mejoramos el proceso de documentación de los flujos de trabajo científicos. Con Docker, los usuarios pueden distribuir estos entornos computacionales a través de imágenes de software utilizando un repositorio público llamado DockerHub. Por lo tanto, nuestro objetivo es abordar la conservación física. Con el fin de lograr una conservación lógica, se construye un sistema de anotador para las imágenes Docker que describe el sistema de gestión del flujo de trabajo, así como sus dependencias mediante el desarrollo de un sistema de anotador para las imágenes Docker antes. De esta manera, se pretende abordar la conservación física. Para validar la solución se reproducen cuatros experimentos computacionales diferentes. Estos experimentos abarcan diferentes sistemas, lenguajes y configuraciones, lo que demuestra que nuestro enfoque es genérico y puede aplicarse a cualquier experimento computacional. Realizamos estos experimentos, los describimos lógicamente y a continuación los reproducimos en base a las descripciones lógicas que obtuvimos anteriormente. Para validar el enfoque, comparamos los resultados de los experimentos.

Capítulo 2

Estado del arte

2.1. Conservación de procedimiento científicos

Distintas áreas de la ciencia han adoptado técnicas y herramientas para conservar el procedimiento. Por ejemplo, investigadores en bio-informática ha incorporado los workflows para distintos análisis: Doblamiento de proteínas [8], secuencias de DNA y RNA [9, 10] y la detección de ondas gravitacionales [11]. Los workflows científicos son métodos que permiten representar un conjunto de pasos computacionales. Estos pasos pueden ser la obtención de los datos de entrada, transformaciones o generación de los resultados. La representación de los workflow se construye en un lenguaje abstracto para simplificar la complejidad. El conjunto de pasos se pueden representar como gráficos sin ciclos y dirigidos, donde cada paso computacional es representado por un nodo y las dependencias entre los pasos son representado por los arcos. El uso de sistemas de manejo de workflows científicos *Scientific Workflow management Systems (WMS)* permiten diseñar abstractamente, ejecutar y compartir el procedimiento científicos.

Dado que los workflows formalmente describen la secuencia de tareas computacionales y administración de datos, es fácil encontrar el camino de los datos producidos. Un científico podría ver el workflow y los datos, seguir los pasos y llegar al mismo resultado. En otras palabras, la representación del workflow facilita la creación y administración de la computación y además construye una base en la cual los resultados pueden ser validados y compartidos.

Sin embargo, múltiples estudios han mostrado las dificultades reproducir los resultados de los experimentos.

2.1.1. Sistemas de administración de workflows

Cómo se menciono anteriormente, los workflows científicos permiten a los usuarios expresar fácilmente tareas computacionales de varios pasos, por ejemplo, recuperar datos de un instrumento o una base de datos, reformatar los datos y ejecutar un análisis. Un workflow científico describe las dependencias entre las tareas y la mayoría de los casos se describe como un gráfico acíclico dirigido (DAG), donde los nodos son tareas y los bordes denotan las dependencias de las tareas. Una propiedad que define un workflow científico es que gestiona el flujo de datos. Es por ello, que las tareas en un workflow científico varían ampliamente según las necesidades del autor, los tipos pueden ser tanto como tareas cortas en serie o tareas paralelas muy grandes (e.g, utilizando Message Passing Interface - MPI) rodeadas de un gran número de pequeñas tareas en serie utilizadas para el pre y post procesamiento. La interpretación y ejecución de los workflows son manejados por un sistema de manejo de workflows (WMS) que administra la ejecución de la aplicación en la infraestructura. Un WMS puede ser considerado como una capa intermedia necesaria para la abstracción y orquestación de procedimiento científico. A continuación se describe algunos de los WMS más populares.

Actualmente, existen múltiples WMS que han sido generado por diversas comunidades.

2.1.2. Galaxy

Galaxy [12] es un sistema de gestión de almacenes basado en la web que tiene como objetivo llevar las capacidades de análisis de datos computacionales a usuarios no expertos en el campo de las ciencias biológicas. Los principales objetivos del marco de trabajo de Galaxy son la accesibilidad a las capacidades computacionales biológicas y la reproducibilidad del resultado del análisis mediante el seguimiento de la información relacionada con cada paso del proceso.

2.1.3. Taverna

Taverna [13] es un WMS basado en servicios web, ya que todos los componentes del flujo de trabajo deben implementarse como servicios web (ya sea localmente o utilizando un servicio remoto disponible). Taverna es capaz de integrar los servicios web de Soaplab26, REST (Fielding, 2000) y WSDL (Christensen et al., 2001). Ofrece una amplia gama de

servicios para diferentes capacidades de procesamiento, tales como servicios Java locales, servicios de procesador R estadístico, scripts XPath o servicios de importación de hojas de cálculo.

2.1.4. Pegasus

Pegasus [11] es un WMS capaz de gestionar flujos de trabajo compuestos por millones de tareas, registrando datos sobre la ejecución y resultados intermedios. En Pegasus, los flujos de trabajo se describen como flujos de trabajo abstractos, que no contienen información de recursos, o las ubicaciones físicas de datos y ejecutables.

2.1.5. WINGS

WINGS [14] no puede ser considerado como un WMS apropiado por sí mismo, ya que no proporciona características de ejecución y promulgación del flujo de trabajo. Sin embargo, es ampliamente conocido por el diseño del flujo de trabajo. WINGS puede considerarse como una herramienta de diseño de alto nivel y orientada a los dominios, cuyos flujos de trabajo pueden ejecutarse posteriormente en diferentes motores de flujo de trabajo, como Pegasus o Apache OODT²⁹.

2.1.6. dispel4py

dispel4py [15] es una biblioteca Python (Rossum, 1995) para describir flujos de trabajo. Describe flujos de trabajo abstractos para aplicaciones intensivas en datos, que luego se traducen y ejecutan en plataformas distribuidas (por ejemplo, Apache Storm, clusters MPI, etc.).

2.2. Conservación de equipamiento

Comúnmente el equipamiento en otras disciplinas no es un problema a resolver dado que los recursos utilizados son conocidos, no-variables y estándares. Por ejemplo, la utilización de probetas, microscopios u otros elementos físicos. Consecuentemente, los investigadores pueden nombrarlos e identificarlos de forma manual en los procedimientos de sus cuadernos de laboratorio. Lo que permite que otro investigador conozca cuáles fueron las

herramientas utilizadas en el experimento. Aunque existen excepciones como en la ciencia de biología, donde ciertos recursos son materiales que son utilizados en los procedimientos. En estos casos, los investigadores deben describir los materiales incluyendo información como marcas, composición y otros. En otras ciencias como la astronomía se utilizan recursos de alta tecnología, donde también es necesario documentar las características de hardware y configuraciones utilizadas en el proceso experimental. En las ciencias de la computación sucede un caso similar, dado que los recursos computacionales son una componente requerida en la ejecución del sistema. Es por ello, que esta comunidad no puede ser la excepción respecto a la descripción de los recursos. Por lo tanto, los autores deben poder documentar computadores, clusters, servicios web, componentes de software, etc., en el contexto de sus experimentos.

Diversos trabajos han estudiado el estado actual de la reproducibilidad en las ciencias de computación, en [16] se estudia el factor de decaimiento de un conjunto workflows científicos almacenado en myExperiment ¹ que fueron diseñados para el WMS Taverna [13] del área de biología. Para ello, los autores utilizaron cuatro conjuntos de paquetes de workflows y clasifican el decaimiento de los workflows en cuatro categorías: recursos de terceros volátiles, datos de ejemplos faltantes, ambiente de ejecución faltante y descripciones insuficientes sobre los workflow. El estudio muestra que casi el 80 % de workflows fallan al ser reproducidos, con un 12 % de esos fallos debido al ambiente de ejecución faltante y 50 % recursos de terceros volátiles. Estas dos últimas categorías están asociadas a la conservación del ambiente computacional del experimento. En [17], los autores describen un procedimiento para preservar el software, argumentando que el software es frágil a los cambios de ambiente ya sea hardware, sistema operativo, versiones de las dependencias y configuración. Los autores afirman que el software no puede ser preservado con la metodología anterior de sólo mantener su código binario ejecutable. Por ello, introducen el concepto de adecuación de la preservación, una métrica para medir si la preservación de conjunto de funcionalidades de componente de software luego de un proceso reproducción.

De la misma manera, editoriales se ha enfocado en intentar resolver los desafíos en la publicación de trabajos científicos. Por ejemplo, Elsevier formó el *Executable Paper Grand Challenge* para abordar la dificultad de reproducibilidad de los resultados en las ciencias de la computación, ellos argumentan que los bloques vitales y necesarios de información para replicar los resultados -por ejemplo, software, código, grandes conjuntos

¹<https://www.myexperiment.org/home>

de datos- no suelen estar disponibles en el contexto de una publicación académica. Y *Executable Paper Grand Challenge* creó una oportunidad para que los científicos diseñen soluciones que capturen esta información y proporcionen una plataforma para que estos datos puedan ser verificados y manipulados. En 2011, [18] se argumenta que el documento de investigación en su estado actual ya no es suficiente para reproducir, validar o revisar completamente los resultados y conclusiones experimentales de un documento. Esto impide el progreso científico. Para remediar estas preocupaciones, presentan Paper Mâché, un nuevo sistema para crear documentos de investigación dinámicos y ejecutables. La principal novedad de Paper Mâché es el uso de máquinas virtuales, que permite a los lectores y revisores ver e interactuar fácilmente con un documento y poder reproducir los principales resultados experimentales. En la misma línea, CernVM [19] propuso la utilización de máquinas virtuales para resolver problemas de reproducibilidad en la ciencia. CernVM es un sistema para el uso de máquina virtuales capaz de ejecutar aplicaciones físicas de los experimentos relacionados al *Large Hadron Collider* (LHC) en el *European Organization for Nuclear Research* (CERN). Su objetivo es proporcionar un entorno completo y portátil para desarrollar y ejecutar el análisis de datos LHC en cualquier ordenador del usuario final (portátil, de sobremesa), así como en la red, independientemente de las plataformas de sistemas operativos (Linux, Windows, MacOS). La motivación del uso de técnicas de virtualización que permite separar los recursos de computación desde la infraestructura subyacente.

Algunos autores han expuesto la necesidad de capturar y preservar el entorno de ejecución de un ejecución del experimento, proporcionando herramientas para analizar y empaquetar los recursos involucrados en él. ReproZip [20] busca captar el conocimiento sobre una infraestructura e intentar reproducirla en un nuevo entorno. Esta herramienta lee los componentes de infraestructura involucrados en la ejecución (archivos, variables de entorno, etc.) y almacena esta información en una base de datos MongoDB ². A continuación se recogen y empaquetan los elementos descritos. Luego, el sistema debe desempaquetar los elementos en otra máquina para reproducir el experimento. Sin embargo, este tipo de enfoque que empaqueta los componentes físicos de una infraestructura determinada presenta limitación en la práctica, debido que los paquetes deben ser ejecutado en una máquina destino similar. Otro ejemplo es TOSCA (Topology and Orchestration Specification for Cloud Applications), TOSCA es un ejemplo de las soluciones que han definido sintaxis

²<https://www.mongodb.com/es>

para describir la ejecución de los ambientes computacionales. TOSCA es un lenguaje de código abierto utilizado para describir las relaciones y dependencias entre servicios y aplicaciones que residen en una plataforma de computación. TOSCA puede describir un servicio de computación en nube y sus componentes y documentar la forma en que están organizados y el proceso de orquestación necesario para utilizar o modificar dichos componentes y servicios. Esto proporciona a los administradores una forma común de gestionar aplicaciones y servicios en la nube, de modo que esas aplicaciones y servicios puedan ser portátiles a través de las diferentes plataformas de los proveedores de cloud computing. Otro esfuerzo importante relacionado a nuestro trabajo incluye la descripción de los ambientes computacionales utilizando ontologías es TIMBUS. El proyecto se focaliza en preservar procesos de negocios y su infraestructura computacional. Para ello, propusieron un extractor para extraer y anotar los componentes de Software y Hardware, éstas anotaciones son almacenadas según un conjunto de ontologías con el objetivo de gestionar la preservación y reejecución de los procesos de negocio. Sin embargo, el enfoque extractor del Proyecto Timbus no es adecuado para ser utilizado en cualquier sistema de virtualizada ya que aumenta la complejidad del ambiente y generando ruido. Además, exige ejecutar el ambiente computacional lo cual conlleva altos costos computacionales, disminución en la escalabilidad y creación de brechas de seguridad.

En el enfoque de describir los recursos computacionales, los autores en [6] identificaron dos enfoques para conservar el ambiente computacional de un experimento científico: la conservación física, donde los objetos de investigación dentro del experimento se conservan en un entorno virtual; y la conservación lógica, donde las principales capacidades de los recursos en el entorno se describen utilizando vocabularios semánticos para permitir al investigador reproducir un entorno equivalente. Para ello, definieron un proceso para documentar la aplicación de flujo de trabajo y su sistema de gestión relacionado, así como sus dependencias. Además, los autores propusieron *The Workflow Infrastructure Conservation Using Semantics ontology* (WICUS). WICUS es una red de ontologías OWL2 (Web Ontology Language) que implementan la conceptualización de los principales dominios de una infraestructura computacional. Como: Hardware, Software, Workflow y Recursos Informáticos. Los autores argumentan este trabajo debido a que el workflow científico requiere un conjunto de componentes de software, y los investigadores deben saber cómo desplegar esta pila de software para lograr un entorno equivalente. Sin embargo, este proceso se realiza de forma manual, dejando mucho trabajo a los científicos. Además,

los autores afirman que la conservación de los ambientes computacionales comúnmente se logra utilizando un enfoque físico dado que la conservación física permite compartir fácilmente un ambiente computacional con otros investigadores y ellos pueden reproducir el experimento utilizando en el mismo ambiente. Sin embargo, los esfuerzos necesarios para mantener la infraestructura son altos y no hay garantías que no sufran un proceso de decaimiento [21]. Consecuentemente, la mayoría de los trabajos dejan fuera del ámbito de aplicación la conservación física del entorno informático del workflow (basándose en la infraestructura elegida). Pese a que la conservación lógica y física son deseadas para lograr la reproducibilidad del experimento.

En diversos trabajos [22, 23, 24, 25] se ha propuesto la utilización de Docker como un reemplazo al uso de máquinas virtuales como ambiente computacionales científicos, los trabajos argumentan que Docker presenta beneficios de portabilidad, documentación precisa de la instalación y configuración, manejo de control de versiones de las imágenes y fácil adopción por desarrolladores. Un ejemplo de uso de Docker para la reproducibilidad es Biocontenedores [22]. Biocontenedores es un framework de código abierto y orientado a la comunidad que proporciona entornos ejecutables independientes de la plataforma para el software de bioinformática. Biocontenedores permite a los laboratorios instalar fácilmente software de bioinformática, mantener múltiples versiones del mismo software y combinar herramientas de análisis. Biocontenedores se basa en los populares proyectos de código abierto Docker ³, Singularity ⁴ y rkt ⁵, que permiten que el software sea instalado y ejecutado bajo un entorno aislado y controlado. Sin embargo, en [24, 26] los autores exponen que Docker no controla que paquetes instalados en las imágenes y no existe una descripción completa de los componentes de la imagen y consecuente del contenedor. Por lo tanto, las imágenes Docker funcionan como una caja negra, lo que significa que los usuarios saben cuál es el paquete que se ejecuta dentro del contenedor pero no conocen las versiones o los otros paquetes necesarios para ejecutarlo.

Respecto a la descripción de los componentes de una imagen Docker, en [27] analizó más de 300.000 imágenes de Docker almacenadas en el repositorio oficial de Docker. Los autores encontraron que en promedio las imágenes que contiene el Docker Hub (sistema de almacenamiento de imágenes) son más de 180 vulnerabilidades, siendo la raíz de tal

³<https://www.docker.com/>

⁴<https://www.sylabs.io/singularity/>

⁵<https://coreos.com/rkt/>

cantidad de vulnerabilidades el hecho de que muchas imágenes no han sido actualizadas en varios días y que muchas de estas vulnerabilidades se propagan de imágenes de padres a hijos. Los autores encontraron correlaciones entre las imágenes más influyentes y los paquetes vulnerables mejor clasificados, lo que sugiere que la fuente de esa cantidad de vulnerabilidades era probablemente el resultado de la propagación de un pequeño número de imágenes populares (debido a la falta de actualización de las imágenes principales). Los autores utilizaron el software Clair ⁶ de la empresa CoreOS⁷. En términos de ingeniería ontológica, los autores en [28] presentan la ontología Smart contenedor que extiende DOLCE [29] y modela Docker en términos de sus interacciones para desplegar imágenes. Otro trabajo relacionado, [30] describe cómo usar RDF para representar archivos de construcción de Docker.

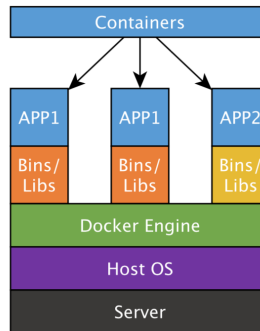
2.3. Docker

Durante los últimos veinte años el uso de tecnologías de virtualización ha aumentado rápidamente, esta tecnología permite dividir el sistema de un computador en múltiples ambientes virtuales.


Uno de los usos comunes para esta tecnología es la virtualización de servidores en *datacenters*. Con la virtualización de servidores, un administrador de sistemas puede crear una o más instancias virtuales o máquinas virtuales (VMs) en un servidor. Este enfoque hoy se utiliza comúnmente en *datacenters* y también en plataformas de *cloud* como Amazon EC2, RackSpace, Dreamhost y otros [?]. El crecimiento del uso de la virtualización ha hecho necesario la búsqueda de una solución que permita tener un ambiente escalable y seguro. Un gran número de soluciones han nacido en el mercado y se pueden clasificar en dos tipos: *contenedor-based virtualization* y *Virtualización basada en hipervisores*. *contenedor-based virtualization* es una virtualización liviana a nivel de software usando el kernel de host para correr múltiples ambientes virtuales. Estos ambientes son nombrados con contenedores (contenedores). Y hoy en día Linux-VServer, OpenVZ, libcontenedor y Linux contenedor (LXC) son las principales implementaciones para utilizar contenedores. En la figura 2.1a se puede observar que la arquitectura de *contenedor-based virtualization*. Los contenedores utilizan el sistema operativo compartido del ambiente virtualizador (host)

⁶<https://github.com/coreos/clair>

⁷<https://coreos.com/>



(a) Virtualización basada en contenedores: los contenedores comparten el sistema operativo del host y por lo tanto no necesitan una copia.



(b) Virtualización basada en máquinas virtuales: las máquinas virtuales requieren un sistema operativo para cada uno.

Figura 2.1: Dado que un contenedor comparte recursos, esto reduce significativamente el uso de almacenamiento en comparación a las máquinas virtuales.

y por lo tanto no es necesario nuevamente el sistema operativo para cada contenedores que se está ejecutado. Para el sistema operativo del *host*, los procesos del contenedor no son especiales y se tratan como cualquier otro proceso que ejecuta sobre el kernel. Sin embargo, los contenedores son ambientes aislados y con recursos limitados y estas características se lograr a través de herramientas del Kernel [?].

Las diferencias entre la virtualización basada en contenedores y máquinas virtuales presentan características interesantes para la ejecución de aplicaciones y workflows. Dado que un contenedor comparte recursos con el sistema operativo, como las bibliotecas, ésto reduce significativamente la necesidad de reproducir el código del sistema operativo, y significa que un servidor puede ejecutar varios ambientes con una sola instalación del




Figura 2.2: Docker

sistema operativo. Por lo tanto, los contenedores son excepcionalmente ligeros: sólo tienen un tamaño de megabytes y sólo tardan unos segundos en arrancar. En comparación con los contenedores, las máquinas virtuales tardan minutos en funcionar y son un orden de magnitud mayor que un contenedor equivalente. [?, ?, ?]. A partir de esto nace la motivación de la utilización de contenedores con una alternativa para alcanzar la conservación física de los ambientes. Docker es un proyecto open-source que utiliza la tecnología de los contenedores (libcontenedor) para “construir, migrar y correr aplicaciones distribuidas”. Actualmente utilizado por Yelp, Spotify, entre otros [?, ?] Docker es una solución que simplifica el uso de los contenedores que han estado presente durante más de una década. Primero provee una interfaz simple y segura para crear y controlar contenedores [?], segundo permite a los desarrolladores empaquetar y correr sus aplicaciones de manera sencilla y además se integra con herramientas terceras que permiten administración y despliegue como Puppet⁸, Ansible⁹ y Vagrant¹⁰. Y diversas herramientas de orquestación como Mesos [?], Shipyard [?], Kubernetes [?], RancherOS [?] y Docker Swarm [?].

Docker puede separarse en dos grandes componentes Docker Engine y Client. Docker Engine es una herramienta liviana y portable para administrar la virtualización. Y Docker Client, provee una interfaz para interactuar con los contenedores con los usuarios a través de RESTful APIs[?].

Docker utiliza una arquitectura de cliente-servidor, Docker Client interactúa con Docker Daemon y este construye, maneja y corre los contenedores. Docker Client y Docker Daemon pueden correr en el mismo host o se puede conectar el cliente desde un host remoto. El cliente y el Daemon se comunican en forma de sockets o RESTful API [?].

⁸<https://puppet.com>

⁹<https://ansible.com>

¹⁰<https://vagrant.com>

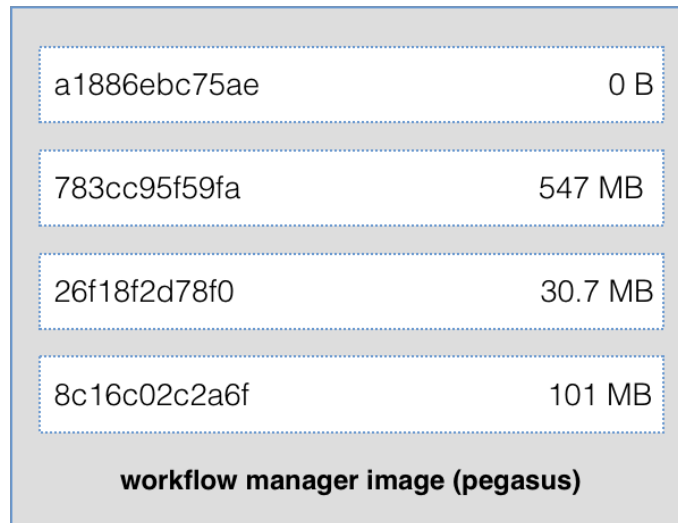


Figura 2.3: Las imágenes Docker con compuestas por capas. La última capa (a1886ebc75ae) es la única capa en modo escritura.

Una imagen de Docker (*Docker Image*) es una plantilla de solo lectura. Por ejemplo, una imagen puede contener las herramientas básicas de Ubuntu con Apache y una aplicación web instalada o simplemente el sistema operativo. Las imágenes son usadas para construir *Docker contenedores*. Cuando el usuario crea cambios en el contenedor, este cambio no se realiza en la imagen, sino que Docker añade una capa adicional con los cambios de la imagen[?]. Por ejemplo, si el usuario utiliza una imagen base de Debian, luego añade el paquete emacs y luego añade el paquete apache, el estado de capas estaría representado por la figura 2.3 [?]. Esto permite tener un proceso de distribución de imágenes más eficiente dado que solo es necesario distribuir las actualizaciones [?]. El sistema de archivos descrito anteriormente se denomina una sistema de archivo basado en capas.

Docker Hub es un repositorio que almacena dos tipos de repositorios públicos, oficiales y comunitarios. Los repositorios oficiales contienen imágenes públicas y verificadas de empresas y proveedores de software de renombre, como Canonical, Nginx, Red Hat y el propio Docker. Al mismo tiempo, los repositorios comunitarios pueden ser repositorios públicos o privados creados por usuarios y organizaciones individuales, que comparten sus aplicaciones y resultados.

Usando ese repositorio y una línea de comandos, es posible descargar e implementar imágenes Docker localmente, ejecutando el contenedor en un entorno host, y ejecutando así el software dentro de la imagen. Los usuarios pueden crear y almacenar imágenes en el registro del Docker Hub, creando un archivo descriptor llamado Dockerfile o ampliando uno

existente. Este descriptor describe cuáles son los paquetes de software que estarán dentro de la imagen, construye la imagen y finalmente la sube al Docker Hub. Sin embargo, Docker Hub no controla qué paquetes hay en las imágenes, si la imagen se desplegará correctamente o si las imágenes pueden tener algún problema de seguridad. Así, las imágenes Docker funcionan como una caja negra, lo que significa que los usuarios saben sólo paquetes principales que se ejecutan dentro del contenedor pero no conocen los otros paquetes necesarios para ejecutarlo. Hay dos maneras de subir imágenes a un repositorio de usuario, ya sea enviar la imagen desde un host local o automatizando ese proceso desde un repositorio Github. Para enviar una imagen al Docker Hub, los usuarios necesitan nombrar sus imágenes locales usando su nombre de usuario Docker Hub, y el nombre del repositorio que han creado. Después, los usuarios añaden múltiples imágenes a un repositorio añadiéndole la versión : <tag>. Esta es toda la información que normalmente tienen las imágenes Docker en DockerHub, siendo por tanto casi imposible reproducir el entorno de ejecución si se modifica alguno de los paquetes de software utilizados dentro de las imágenes.

DockerHub permite a las comunidades científicas almacenar y compartir, conservando el contenido de los contenedores, así como comprobar la identidad del editor y recuperar los contenedores de interés. Sin embargo, la información del contenido de cada repositorio no siempre es accesible de forma clara. Como la mayoría de las veces sólo se proporcionan descripciones cortas de los contenedores, no es fácil para el usuario entender qué componentes están instalados en ellos. Incluso cuando los archivos Dockerfile están disponibles, no son lo suficientemente intuitivos de entender cuáles paquetes están siendo desplegados por cada comando. Además, es posible que en el contenedor existan algunos componentes que no estén especificados por el propio Dockerfile. Para abordar este problema proponemos un enfoque automático para analizar el contenido de un contenedor Docker y extraer la información sobre los componentes de software instalados en él. Esta información se convierte en datos semánticos, codificados como RDF bajo el conjunto de ontologías.

Los contenedores Docker consiste de un ambiente virtual con: con archivos de usuarios y metadata, cada contenedor es construido a partir de una imagen base como se mencionó anteriormente. Esta imagen indica la base del contenedor y se asocia un proceso inicial, el cual debe correr cuando el contenedor es iniciado [?]. Para describir los pasos incluidos en la creación de un contenedor, se ejemplificará con la creación de uno.

- *Docker Client* le informa al Docker que debe correr un contenedor.

Listing 2.1: Ejemplo de la ejecución de un contenedor utilizando la imagen Docker

```
docker run -i -t ubuntu /bin/bash
```

- En este caso el comando `/bin/bash` será el proceso `init` o `0` del contenedor
- **Traer la imagen:** Docker verifica la existencia de la imagen Ubuntu y sino existe en el host, entonces Docker descarga desde el repositorio ya sea privado o publico. Si la imagen existe entonces crea el contenedor.
- **Asignar el sistema de archivos y montar la capa de escritura:** El contenedor es creado en el sistema de archivos y se añade una capa en modo escritura en la imagen.
- **Crear la red y conectar con la interfaz puente:** Crea la interfaz de red que permite que contenedor pueda enviar y recibir paquetes con el host a través del puente (`docker0`).
- **Asignar un IP:** Asigna una dirección IP del pool al contenedor
- **Capturar la salida estándar y de errores:** Dependiendo de la configuración de contenedor, Docker enviará a los registros de errores hacia el mismo servidor u otro externo.

Docker utiliza dos funcionalidades de Linux *namespaces* y *cgroups* para crear ambientes virtuales para los contenedores. *cgroups* o *control groups* proveen un mecanismo de contabilidad y limites de recursos que pueden utilizar los contenedores[?]. Los *namespaces* proveen del aislamiento que es llamado contenedor. Cuando sea crea un contenedor, Docker crea un conjunto de *namespaces* para el contenedor. Los *namespaces* utilizados por Docker: `mount` (`mnt`) para el manejo del montaje, `PID` para el aislamiento de los procesos, `net` para el manejo de interfaces y `IPC` para acceder a recursos de IPC. Docker logra el aislamiento de los procesos separando los procesos en *namespaces* y limitando los permisos de los procesos a otros contenedores. *PID namespaces* (añadido en el kernel $\geq 2,6,3,2$) es el mecanismo utilizado, logrando que un proceso que se encuentra en el contenedor solo pueda ver procesos que se encuentra en ese contenedor. Por lo tanto un atacante no puede observar procesos de otro contenedor, lo que aísla al contenedor este nivel [?, ?]. Docker usa *mount namespaces* o *filesystem namespaces* para aislar los *filesystems* asociados a los

contenedores. De la misma forma que ocurre con los procesos, los eventos del sistema de archivo que ocurre en el contenedor sólo afectan a ese contenedor.

Cómo se menciono anteriormente, Docker utiliza *cgroups* que permite especificar que *device* puede ser utilizado con el contenedor. Esto bloquea la posibilidad de crear y usar *device nodes* que puedan ser utilizados para atacar el host. Los *device nodes* que son creados para cada contenedor por defecto: son: `/dev/console`, `/dev/null`, `/dev/zero`, `/dev/full`, `/dev/tty*`, `/dev/urandom`, `/dev/random`, `/dev/fuse`. [?] IPC (*inter-process communication*) es un conjunto de objetos para el intercambio de datos a través de los procesos, como semáforos, colas de mensajes, segmentos de memoria compartida. Los procesos corriendo en los contenedores utilizan *IPC namespaces* que permite la creación de un *IPC* separado y independiente para cada contenedor, con esto se previene que procesos en un contenedor interfieran con otros contenedores o el host. Para cada contenedor, Docker crea una red independiente usando *network namespaces*, compuesta de su propia IP, rutas, *network devices*. Esto permite que el contenedor pueda interactuar con otro host a través de su propia interfaz. Por omisión, la conexión se realiza gracias al host que provee un *Virtual Ethernet bridge* en la máquina host, llamado `docker0` que automáticamente realiza un *forward* de los paquetes entre las interfaces. Cuando Docker crea un nuevo contenedor, esto establece una interfaz de red virtual con un nombre único que se conecta con el *bridge* (`docker0`) y con la interfaz `eth0` del contenedor [?]. Además para controlan la cantidad de recursos como CPU, memoria, *disk I/O* que el contenedor puede utilizar se utiliza *Cgroups*. A partir de esto se protege contra ataques de DoS.

2.4. Web Semantica

La web semántica es un extensión *World Wide Web* añadiendo un conjunto de estándares diseñado por la *World Wide Web Consortium* con el objetivo de la creación de tecnologías para publicar datos legibles por aplicaciones informáticas. Para lo lograr lo anterior, se añaden metadatos semánticos y ontologías para describir el contenido y generar relaciones entre los datos, esta representación se realiza de una manera formal. Consecuentemente, la información disponible pueden ser procesadas de manera automática mejorando la inter operatividad entre distintos sistemas informáticos que realizan búsquedas sin operadores humanos.

El término fue acuñado por Tim Berners-Lee para una red de datos que puede ser

procesada por máquinas es decir, una red en la que gran parte del significado es legible por máquinas. En [?] se afirma la necesidad de que los datos se transformen desde objetos legible por personas a información semántica diseñada para las máquinas.

Es por ello que la web semántica ha definido diversos estándares para construir una descripción formal de los conceptos, términos y relaciones. Estos estándares definidos por W3C incluyen: RDF, RDFS, SPARQL, Notation3 (N3), N-Triples, Turtle y OWL.

2.4.1. RDF

RDF (del inglés *Resource Description Framework*) es una familia de especificaciones del W3C diseñada como un modelo de datos para metadatos. Fue adoptado como una recomendación del W3C en 1999, mientras que la especificación 1.0 fue publicada el 2004 y la 1.1 el 2014[?].

El modelo de datos RDF se basa en la idea de hacer declaraciones sobre recursos Web (URIs) en forma de expresiones $\langle \text{sujeito}, \text{predicado}, \text{objeto} \rangle$ que son llamados triples RDF. El *sujeito* indica el recurso mientras que el *predicado* denota la relación de éste con el *objeto*. Así podemos decir que un triple RDF sigue la clásica notación entidad - atributo - valor de los modelos orientados a objetos, permitiendo además, gracias a su simpleza, modelar todo tipo de conceptos abstractos.

2.4.2. RDFS

RDFS (de las siglas del inglés *Resource Description Framework Schema*, también llamado RDF Schema) es un vocabulario que extiende RDF proveyendo un set de clases y propiedades que mejoran la creación de modelos como son: `Class` para declarar clases, `subClassOf` para denotar herencia, `range` y `domain` para el rango y dominio de cierta propiedad (`rdf:Property`), entre otras.

RDF fue presentado en 1998 e introducido finalmente como recomendación del W3C el 2004[?].

2.4.3. OWL

OWL (del inglés *Web Ontology Language*) es una familia de lenguajes para la creación de ontologías complejas. Agrega lógica computacional para que las relaciones hechas con

este lenguaje puedan ser procesadas con el fin de verificar la consistencia de la información o generar información implícita.

La versión actual de OWL se conoce como “OWL 2” y fue publicada el 2009 como una revisión y extensión de la versión inicial publicada el 2004[?]. Generalmente cuando se habla de “OWL” nos referimos a la versión del 2004.

2.5. Sistemas de paquetes y vulnerabilidades

Capítulo 3

Objetivos de trabajo

El principal objetivo de este trabajo es complementar enfoques existentes para la reproducibilidad científica en el área de las ciencias de la computación. Para ello, se propone un nuevo enfoque para conservar el ambiente de ejecución del experimento científico. Hemos identificado problemas abiertos, en orden de definir los objetivos de trabajo. Luego, estos objetivos se ven formalizados por un conjunto de hipótesis. Y además, se define un conjunto de hechos que se asumen para restringir el campo de aplicación de la propuesta.

3.1. Problemas de investigación abierto

- Problema 1: La infraestructura computacional utilizada por un workflow científico se encuentra predefinida. Por lo tanto, no existe una definición de los recursos de la infraestructura para ejecutar el experimento. Consecuentemente, pueden existir dificultades para lograr la reproducción del experimento.
- Problema 2: La conservación física de los ambientes computacionales permite mantener y compartir fácilmente el ambiente con la comunidad. Sin embargo, se ha descartado debido a tres problemas: 1. Alta utilización de almacenamiento por parte de las máquinas virtuales, 2. El acceso a los datos almacenados está sujetos a políticas de la organización y 3. Existe un proceso de decaimiento en tiempo. Sin embargo, no se ha estudiado el uso de containers para solucionar el problema.
- Problema 3: Los enfoques actuales anotan los pasos de construcción de los ambientes

computacionales de forma indirecta, por lo tanto, recaen en el científico

3.2. Hipótesis

En función a los problemas abiertos detectados, se definen las siguientes hipótesis:

- Un proceso automático puede describir los requerimientos de ambiente computacional y codificarlo en un formato compatible utilizando modelos semánticos.
- La descripción de containers utilizando modelos semánticos permite la reproducción del ambiente de un experimento científico.

3.3. Objetivos

Para enfrentar los problemas abiertos se definen los siguientes objetivos. Estos objetivos permiten la verificación de la hipótesis y ser una guía para el desarrollo.

- Lograr conservación física y lógica de los ambientes computacionales de un experimento usando Containers
- Implementar un proceso automático capaz de leer la descripción del ambiente y especificar uno nuevo.
- Integrar un sistema que permita el despliegue de estos ambientes computacionales en proveedores de infraestructura e instalar el software apropiado basado al plan de despliegue.

3.3.1. Objetivos específicos

- Adaptar y mejorar modelos estándares que describen ambientes computacionales científicos para incluir virtualización basada en containers.
- Designar una framework para anotar los componentes de ambiente del experimento usando modelos semánticos.

3.4. Restricciones

- Ambientes Linux

Capítulo 4

Representación de ambiente de ejecución

En este trabajo, se argumenta que las descripciones de los ambientes computacionales es necesaria para la reproducción del experimento. Además, la información debe ser la suficiente para comparar y detectar las diferencias entre el ambiente original y el reproducido.

Dado que las imágenes Docker son ambientes aislados y independientes, los componentes de software dentro del contenedor si están relacionado al experimento y no existen componentes relacionados a otros experimentos. Por esta razón, se asegura que las anotaciones no presentarán ruido de otras herramientas o dependencias asociadas. Para realizar una anotación automática de los paquetes instalados, se propone e implementa un sistema de anotación automático. El sistema requiere el nombre de una imagen existente en un repositorio de DockerHub y opcionalmente los datos del repositorio Git que almacena el archivo Dockerfile.

Los pasos asociados del sistema anotación:

1. Consultar a repositorio de imágenes Docker público o privado los metadatos de la imagen. Anotar los metadatos utilizando la ontología propuesta.
2. Descargar cada una de las capas asociadas a la imagen Docker.
3. Sistema anotador consulta a Clair, Clair monta cada una de capas de la imagen, detecta los componentes de software instalados utilizando el sistema de paquete.

4. Obtener la información de Clair, anotar los datos obtenidos por Clair según la ontología.
5. Guardar los datos en una base de datos RDF que permita consulta SPARQL.

4.1. Modelos semánticos

En [6], los autores proponen *The Workflow Infrastructure Conservation Using Semantics ontology (WICUS)*. WICUS es ontología OWL2 (Web Ontology Language) que implementa la conceptualización de los principales dominios de la infraestructura computacional. Estos son: Hardware, Software, Workflow y recursos de computo. Los autores definen que los workflows científicos requieren un conjunto de componentes de software, y los investigadores deben conocer cómo desplegar estos componentes para lograr ambiente equivalente. Considerando que la ontología está relacionada con nuestro trabajo, se utiliza algunas clases y relaciones desde la ontología WICUS:

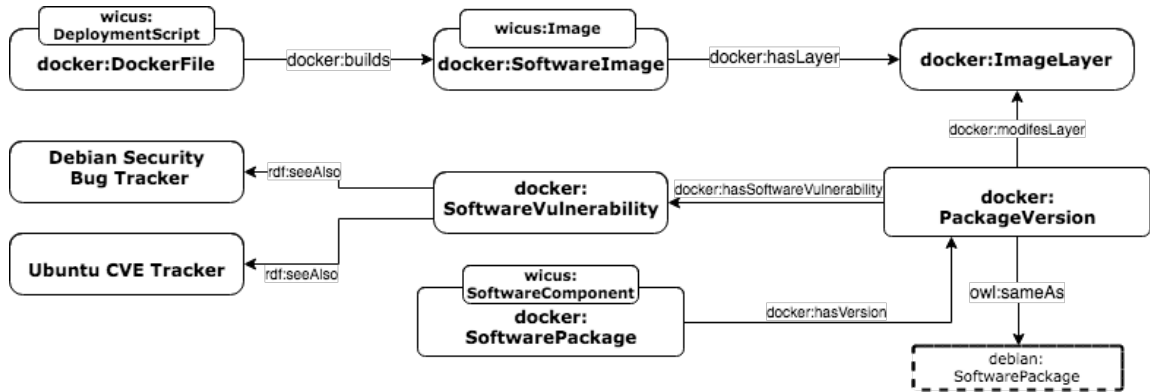
DeploymentPlan: Un plan de despliegue está compuesto de todos los pasos. Y el plan de despliegue permite entender al investigador cuáles fueron los pasos requeridos para construir el ambiente computacional.

DeploymentStep: Cada paso de despliegue es representado por una línea de comando que realiza la instalación, descarga o configuración del ambiente. La información se obtiene desde el archivo DockerFile

SoftwareComponent: Es un componente de software instalado sin una versión específica.

Se define el recurso `dockerpedia:SoftwarePackage` como una subclase de `wicus:SoftwareComponent` para definir los componentes instalados por el gestor de paquetes del sistema operativo u otro. Cada `wicus:SoftwareComponent` tiene una relación `dockerpedia:hasVersion` o `dockerpedia:isVersionOf` que muestra la versión del software instalado. El recurso `dockerpedia:PackageVersion` puede estar afectado por vulnerabilidades representadas por el recurso `dockerpedia:SoftwareVulnerability`. Y las versiones que reparan la vulnerabilidad se encuentran representadas por `dockerpedia:SecurityUpdate`. Una imagen Docker se representa por `dockerpedia:SoftwareImage` y sus capas por el recurso `dockerpedia:ImageLayer`. Los paquetes instalados en la imagen

Figura 4.1: Docker ontology.



están relacionado por `vocab: ContainsSoftware` con su imagen. Finalmente, el sistema operativo es representado por recurso `dockerpedia: OperatingSystem` y cada imagen y capa de la imagen está asociado al recurso.

Una versión completa de la ontología se encuentra disponible en nuestros repositorios ¹ y la versión resumida está representada en la figura 4.1.

4.2. Anotador

El servicio de anotación propuesto cuenta con una interfaz REST para recibir el nombre y la versión de la imagen Docker relacionada con el experimento científico. Para almacenar y interactuar con los datos el sistema de anotación utiliza a Apache Jena. Apache Jena es un framework Java gratuito y de código abierto para la construcción de aplicaciones de Web Semántica y Datos Enlazados. El sistema anotador construye los triples relacionado con el experimento, imagen, capas, componentes de software y vulnerabilidades y se envían usando con la API de Apache Jena que serializa los triples utilizando formatos populares como RDF/XML o Turtle. Esta decisión permite realizar cambios a otra herramienta en caso que Apache Jena no cumpla con los requerimientos de escalabilidad.

El sistema anotación realiza dos tipos de anotaciones: Componentes de software y pasos de construcción.

¹<https://github.com/dockerpedia/ontology/>

4.2.1. Anotaciones de los pasos de construcción

Anotamos el plan de despliegue (Deployment Plan) usando dos métodos. El primero método obtiene los pasos desde el archivo Dockerfile entregado por el usuario, esto permite obtener los pasos y la ubicación de archivo en el repositorio. Usando este método se asegura la reconstrucción del ambiente debido a que cualquier archivo necesario por Dockerfile se encuentra en el repositorio Git. Sin embargo, un usuario puede construir una imagen sin compartir el archivo Dockerfile. En [31] se reporta que el 30 % de las imágenes Docker en DockerHub enlaza su archivo Dockerfile. Por lo tanto, sino existe información del Dockerfile el sistema anotación utiliza el manifiesto de la imagen Docker. Según ² para conocer los pasos, el manifiesto de la imagen provee la configuración y el conjunto de las capas de la imagen

Algunos atributos importantes son:

name: *string* nombre de la imagen

tag: *tag* version de la imagen

architecture: *string* arquitectura del servidor en cuál la imagen ha sido construido. Esta información actualmente no es utilizada por Docker.

fsLayers: *array* lista de las capas que componen la imagen. La estructura contiene los siguientes campos:

blobSum: es un identificador utilizando una función de hash sha256 para cada capa de la imagen

history : *array* Es una lista de datos históricos no estructurados para la compatibilidad con la v1. Contiene el ID de la capa de imagen y el ID de las capas principales de la capa. El historial es una estructura que consta de los siguientes campos:

v1Compatibility : *string* V1Compatibilidad es la información de compatibilidad de V1 en bruto. Esto contiene el objeto JSON que describe la V1 de esta imagen. Una V1Compatibilidad es una estructura que consta de los siguientes campos:

Id: *string* ID de la capa utilizando hash sha256

Parent: *string* ID de la capa madre utilizando hash sha256

²<https://docs.docker.com/registry/spec/manifest-v2-2/>

ContainerConfig: *string* El comando que construyó la capa

4.2.2. Anotaciones de componentes de software

Para lograr la anotación de los componentes de software se utiliza los gestores de paquetes del sistema, un gestor de paquete es una colección de herramientas de software que automatizan la instalación, actualización, configuración y eliminación de componentes de software. Los gestores que paquetes se clasifican en dos tipos: gestor de paquetes del tipo sistema y general:

Gestor de paquetes de sistema: son aquellos vinculados al sistema operativo (e.g., apt de familia Debian, yum de familia RedHat).

Gestor de paquetes generales: son aquellos externos que normalmente son utilizados para instalar un componentes de software de tercero ó un lenguaje específico (e.g., pip, conda, npm). Conda es un sistema paquete frecuentemente utilizado por investigadores al estar relacionado con Jupyter Notebook.

4.2.3. Desafíos del sistema de anotación

La descripción de los componentes de software es fundamental para realizar cuantificar la similitud entre dos o más ambientes computacionales. Un enfoque común para detectar los componentes de software guardar o detectar los comandos que realizan la instalación de software. Por ejemplo, la figura 4.1 muestra los comandos para instalar los componentes de la imagen TensorFlow.

Listing 4.1: Ejemplo de instalación de dependencias para la imagen TensorFlow

```
apt-get install -y --no-install-recommends \  
    build-essential \  
    curl \  
    libfreetype6-dev \  
    libhdf5-serial-dev \  
    libpng12-dev \  
    libzmq3-dev \  
    pkg-config \  
    python \  

```

```
python-dev \  
rsync \  
software-properties-common \  
unzip
```

El enfoque detectaría los componentes: build-essential, curl, libfreetype6-dev, libhdf5-serial-dev, libpng12-dev, libzmq3-dev, pkg-config, python, python-dev, rsync, software-properties-common y unzip. Sin embargo, este enfoque no obtiene información sobre las versiones o las dependencias del software. Utilizando el enfoque propuesto, se puede determinar que la línea anterior instala 184 paquetes.

Como prueba de generación y considerando la popularidad de Jupyter Notebook y conda en la comunidad científica, se extiende Clair para detectar los paquetes instalados por Conda en la imagen. La propuesta incluye e implementa la extensión de Clair para detectar los componentes de software instalados por Conda

En la figura se muestra algunos de los paquetes instalados en la imagen de un workflow construido con Pegasus 4.2, en la figura 4.3 se muestra una vulnerabilidad de paquete glibc instalado en la imagen Pegasus.

Listing 4.2: Ejemplo de triples que muestran los componentes de software de la imagen Pegasus

```
<http://dockerpedia.inf.utfsm.cl/resource/SoftwareImage/  
dockerpedia-pegasus_workflow_images%3Apegasus-4.8.5>  
vocab:containsSoftware <http://dockerpedia.inf.utfsm.  
cl/resource/PackageVersion/libxcb-1.11.1-1ubuntu1>,  
<http://dockerpedia.inf.utfsm.cl/resource/  
PackageVersion/cryptsetup-2%3A1.6.6-5ubuntu2.1> , <  
http://dockerpedia.inf.utfsm.cl/resource/  
PackageVersion/e2fsprogs-1.42.13-1ubuntu1> , <http  
://dockerpedia.inf.utfsm.cl/resource/PackageVersion  
/dbus-glib-0.106-1> , <http://dockerpedia.inf.utfsm  
.cl/resource/PackageVersion/libxmu-2%3A1.1.2-2>
```

Listing 4.3: Ejemplo de triples de la vulnerabilidad de glibc

```
<http://dockerpedia.inf.utfsm.cl/resource/
  SoftwareVulnerability/CVE-2018-6485>
vocab:affectOS      <http://dockerpedia.inf.utfsm.cl/resource/
  OperatingSystem/ubuntu%3A16.04> , <http://dockerpedia.inf.
  utfsm.cl/resource/OperatingSystem/debian%3A9> ;
vocab:description
```

```

vocab:link
```

```

vocab:severity
```

Capítulo 5

Experimentación y evaluación

5.1. Experimentos computacionales

Para validar nuestra propuesta y su aplicación en el contexto de workflows científicos, se ha seleccionado un subconjunto de workflows y WMSs. El subconjunto ha sido seleccionado bajo los criterios de: nivel de utilización de WMS, la diversidad de lenguajes utilizados en el conjunto, y disponibilidad de los materiales del workflow. Es requisito que los materiales deben incluir los datos de ingresos que permitan reproducir de forma completa el workflow, documentación, resultados o anotaciones. Además nos deben permitir comparar los resultados de nuestros ambientes resultantes.

Para cada WMS, hemos construido una imagen estándar. En consecuencia, un investigador puede importar esta imagen e instalar los componentes de software relacionados con el workflow. Esto se puede conseguir utilizando la instrucción `FROM` de Dockerfile. Por ejemplo, el workflow SoyKB utiliza Pegasus como WMS. Por lo tanto, la imagen SoyKb importa la imagen Pegasus. Para entender los requisitos del workflow, nosotros inspeccionamos la documentación disponible y las anotaciones generadas por WICUS [6]. En caso que el WMSs no distribuya su software utilizando Docker, se construye las imágenes, los archivos necesarios como configuraciones y el DeploymentPlan (Dockerfile). Para cada flujo de trabajo los archivos están disponibles en nuestros repositorios.¹ Además, cada DeploymentFile incluye información sobre la imagen utilizando el estándar de la Open Container Initiative² Esta información es:

¹<https://github.com/dockerpedia>

²<https://www.opencontainers.org/>

- `orgopencontainers.image.created` date and time on which the image was built (string, date-time as defined by RFC 3339).
- `orgopencontainers.image.authors` contact details of the people or /item organization responsible for the image (freeform string)
- `orgopencontainers.image.url` URL to find more information on the image (string)
- `orgopencontainers.image.documentation` URL to get documentation on the image (string)
- `orgopencontainers.image.source` URL to get source code for building the image (string)
- `orgopencontainers.image.version` version of the packaged software The version MAY match a label or tag in the source code repository version MAY be Semantic versioning-compatible
- `orgopencontainers.image.revision` Source control revision identifier for the packaged software.
- `orgopencontainers.image.vendor` Name of the distributing entity, /item organization or individual.
- `orgopencontainers.image.licenses` License(s) under which contained software is distributed as an SPDX License Expression.
- `orgopencontainers.image.ref.name` Name of the reference for a target (string).
- `orgopencontainers.image.title` Human-readable title of the image (string)
- `orgopencontainers.image.description` Human-readable description of the software packaged in the image (string)

5.1.1. Pegasus

Pegasus [21] es un WMS capaz de gestionar flujos de trabajo compuestos por millones de tareas, registrando datos sobre la ejecución y resultados intermedios. Cuando se producen errores, Pegasus intenta recuperarse reintentando tareas, reintentando todo el flujo de trabajo,

proporcionando puntos de control a nivel de flujo de trabajo, re-mapeando partes del flujo de trabajo, probando fuentes de datos alternativas para la puesta a disposición de los datos y, cuando todo lo demás falla, proporcionando un flujo de trabajo de rescate que contiene sólo una descripción del trabajo que queda por hacer. Limpia el almacenamiento a medida que se ejecuta el flujo de trabajo, de modo que los flujos de trabajo de datos intensivos tengan suficiente espacio para ejecutarse en recursos limitados por el almacenamiento]. Pegasus lleva un registro de lo que se ha hecho (procedencia), incluyendo las ubicaciones de los datos utilizados y producidos, y qué software se utilizó con qué parámetros. Pegasus lee las descripciones del flujo de trabajo de los archivos DAX. El término DAX.^{es} la abreviatura de "Directed Acyclic Graph in XML". DAX es un formato de archivo XML que tiene sintaxis para expresar trabajos, argumentos, archivos y dependencias. Para crear un DAX es necesario escribir código para un generador de DAX. Pegasus opcionalmente utiliza en HTCondor como administrador de tareas. Por lo tanto, construimos dos versiones para la imagen de Pegasus; una versión tiene ins talado el paquete condor y otra sin él. La justificación de decisión recae en permitir a los científicos utilizar una imagen simple si es necesario. El paquete Pegasus ha sido obtenido del repositorio oficial ³. Los principales requisitos de pegasus son: Java (la versión Java depende de la versión pegasus), python y perl. La figura ?? muestra las dependencias especificadas tanto por el sistema de paquetes y documentación.

Las imágenes se encuentran disponibles en DockerHub ⁴

Soybean Knowledge Base

El workflow SoyKB (Soybean Knowledge Base) [32] permite realizar un proceso de re-secuencia de germoplasma de la soya, con el objetivo de estudiar rasgos como aceites, proteína, resistencia de los nemátodos del quiste de la soya y resistencia al estrés. Pegasus entrega este workflow que implementa tres operaciones: polimorfismo de nucleótido único (SNP), la operación insertar/remover (indel) de la base del genoma del organismo y una análisis utilizando el software GATK ⁵ La figura 5.2 muestra una representación gráfica del workflow, donde se realiza un análisis en paralelo de las muestras. Primero son alineadas con el genoma de referencia, se identifica los indels y SNPs y luego se fusiona y filtra los

³<http://download.pegasus.isi.edu/wms/download/debian>

⁴https://hub.docker.com/r/dockerpedia/pegasus_workflow_images/

⁵<https://software.broadinstitute.org/gatk/>




Figura 5.1: Dependencias de Pegasus. En azul: dependencias necesarias y especificadas en el sistema de paquetes. En verde: necesarias pero no especificadas en el sistema de paquetes. En naranjas: dependencias recomendadas

resultados.

Los componentes de software utilizados por SoyKB se clasifican en dos tipos: propio (en amarillo) y de terceros (en verde). Los componentes principales son: bwa, gatk y picard y el software de tercero java-1.7.0

La evaluación de los resultados se realizó de forma manual al igual que en [6] debido a los pasos aleatorios del workflow. La metodología de la verificación fue la revisión de la estructura de los resultados, el tamaño de los archivos, número de líneas y la inexistencia de errores.

Montage

Montage es un conjunto de herramientas creadas por *NASA Infrared Processing and Analysis Center (IPAC)*, permitiendo generar bajo demanda mosaicos de imágenes astronómicas personalizadas, se utilizan archivos de entrada que cumplen con el estándar del Sistema de Transporte Flexible de Imágenes (FITS) y que contienen datos de imágenes registrados en proyecciones que cumplen con los estándares del Sistema Mundial de Coordenadas (WCS).

La figura 5.4 entregada por Pegasus ilustra el workflow Montage. Cada uno de los nodos de la figura es un software binario que generan la imagen final.

Debido a que el software es un binario, no se encuentra empaquetado. Por lo tanto fue




Figura 5.2: Representación entregada por Pegasus del workflow SoyKB.




Figura 5.3: Dependencias de SoyKb. En amarillo: software propio y en verde software de terceros

descargado de la fuente. La dirección de descarga se encuentran en el plan de despliegue ⁶.

Dado que los resultados de Montage son imágenes se utiliza la herramienta de hash perceptual ⁷ para realizar la comparación entre la imagen reproducida (imagen del cielo de 0,1 grados) frente a la original. Como resultado, se obtiene un factor de similitud de 1,0 (de 1,0) con un umbral de 0,85. Las figuras 5.5a y 5.5b muestran las imágenes resultantes y los archivos resultantes en formato FITS se encuentran en nuestro repositorio ⁸.

⁶<https://github.com/dockerpedia/montage/blob/master/Dockerfile>

⁷<http://phash.org>

⁸https://github.com/dockerpedia/montage_results




Figura 5.4: Representación entregada por Pegasus del workflow Montage. Cada uno de los nodos es una operación y la leyenda indica el nombre de la operación.

5.1.2. dispel4py


dispel4py [15] es una biblioteca Python para describir workflow para aplicaciones intensivas, que luego se traducen y ejecutan en plataformas distribuidas (por ejemplo, Apache Storm, clusters MPI, etc.). El paquete dispel4py ha sido obtenido del repositorio oficial ⁹. Para la instalación el paquete, utilizamos Conda, un gestor de paquetes, dependencias y entornos para lenguajes Python, R, Ruby, Lua, Scala, Java, JavaScript, C/ C++, FORTRAN y que es ampliamente utilizado en entornos de *Jupyter notebook*. Los principales requisitos de dispel4py obtenidos de la documentación son: python2.7, git y python-setuptools. Las imágenes se encuentran disponibles en DockerHub ¹⁰

Internal extinction

Internal Extinction of Galaxies workflow calcula la extinción interna de galaxias desde el catalogo Amiga. Estos datos son obtenidos a partir de un servicio llamado Observatorio Virtual, que es una red de herramientas y servicios que implementan estándares publicados por la *International Virtual Observatory Alliance* (IVOA). El workflow calcula una propiedad, que representa la extinción de polvo dentro de las galaxias y que es un coeficiente de

⁹https://github.com/rosafilgueira/dispel4py_workflows

¹⁰<https://hub.docker.com/r/dockerpedia/>



(a) Resultados originales obtenidos de WICUS (b) Resultados reproducidos por nuestra propuesta

Figura 5.5: Los resultados obtenidos con el nuevo ambiente son iguales




Figura 5.6: Pasos necesarios para el workflow internal extinction

corrección necesario para calcular la luminosidad óptica de una galaxia.

El workflow primero lee el archivo de entrega que contiene la declinación y ascensión recta de 1051 galaxias. Luego, utiliza estos valores para realizar consultas al observatorio virtual. Los valores resultantes de las consultas son filtrados y se seleccionan sólo los valores que correspondan al tipo morfológico (Mtype) y al rango de los ejes del isófito 25 mag/arcsec^2 (logr25) de las galaxias. Finalmente, se calcula su extinción interna. La figura 5.6 muestra los pasos del workflow

Nuestra investigación inicial sobre las dependencias para la ejecución de Internal extinction muestra que el software principal requeridos es el siguiente: `requests==2.20.0`, `python=2.7.15=h33da82c_4`, `numpy=1.15.0=py27h1b885b7_0` y `astropy==2.0.9`

Seismic Ambient Noise Cross-Correlation

Seismic Ambient Noise Cross-Correlation workflow (o *xcorr workflow*) es parte del proyecto *Virtual Earthquake and seismology Research Community e-science environment*




Figura 5.7: Pasos necesarios para el workflow internal extinction

in Europe (VERCE). El objetivo del workflow es la prevision de riesgos producidos por terremotos y erupciones volcánicas. Estos eventos en ciertos casos van precedidos o acompañados de cambios en las propiedades geofísicas de la Tierra, como la velocidad de las olas o la velocidad de los eventos.

Para lograr desarrollo de métodos fiables de evaluación de riesgos para estas amenazas requiere un análisis en tiempo real de los datos sísmicos y un pronóstico verdaderamente prospectivo y pruebas para reducir los sesgos.

xcorr logra lo anterior a través de dos etapas, la primera etapa es un preprocesamiento de series de tiempo de una estación sísmica llamadas trazas, en esta etapa se realiza una serie de tratamientos y el procesamiento de cada traza es independiente del procesamiento de otras trazas, haciendo que esta fase sea paralela. Luego la segunda etapa empareja todas las estaciones y calcula la correlación cruzada para cada par. La figura 5.7 muestra los pasos del workflow.

Nuestra investigación inicial sobre las dependencias para la ejecución indica que los componentes de software necesarios son: `python=2.7.15=h33da82c_4`, `obspy=1.1.0=py27h3` y `numpy=1.15.0=py27h1b885b7_0`

5.1.3. WINGS

WINGS es un sistema de flujo de trabajo semántico que ayuda a los científicos en el diseño de experimentos computacionales. En WINGS, se especifica cómo deben ser procesados los conjuntos de datos por una serie de componentes del software en una configuración particular. WINGS a diferencia de los otros sistemas de workflows utiliza imágenes Docker para su distribución. Nuestra investigación inicial sobre las dependencias




Figura 5.8: Dependencias de WINGS

indica que los principales requisitos de WINGS son: Java 1.8, Tomcat 8.5, Docker. La figura 5.8 muestra en mayor detalles las dependencias especificadas tanto por el sistema de paquetes o documentación.

Las imágenes se encuentran disponibles en DockerHub ¹¹

MODFLOW-NWT

MODFLOW es el modelo hidrológico modular del *United States Geological Survey* (USGS). MODFLOW se considera una norma internacional para simular y predecir las condiciones de las aguas subterráneas y las interacciones entre las aguas subterráneas y superficiales. El USGS MODFLOW-NWT es una formulación de Newton-Raphson para MODFLOW-2005 con el objetivo de mejorar la solución de problemas de flujo, secado y rehumectación de aguas subterráneas no confinadas.

La figura 5.9 muestra la estructura principal del workflow, desarrollado con pipeline

¹¹<https://hub.docker.com/r/dockerpedia/wings/>

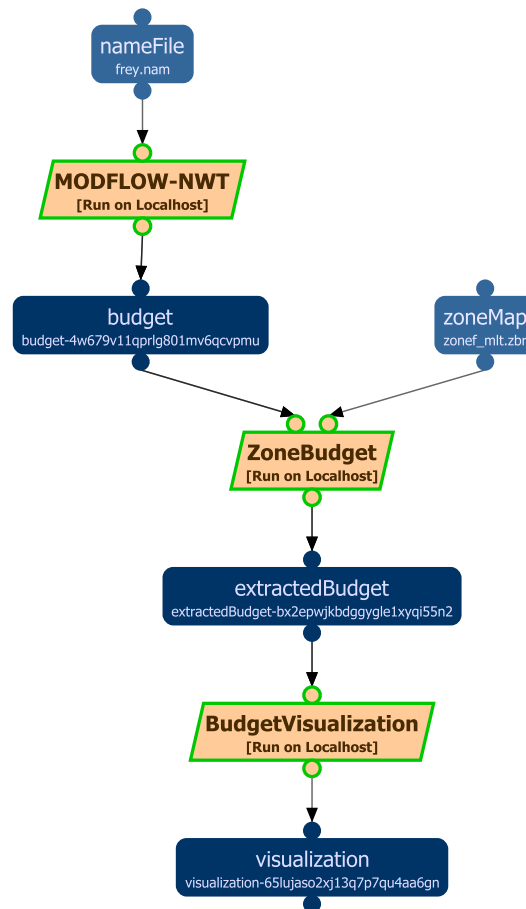


Figura 5.9: Figure caption.


compuesto por tres pasos. El proceso inicia leyendo el modelo a utilizar. Luego, el archivo de zona se usa para especificar arreglos de zonas que van usarse y finalmente se genera una visualización que muestra la cantidad de millones de galones por día en zona. Las figuras 5.10a y 5.10b muestran los resultados generados por el ambiente original y reproducido respectivamente.

5.2. Conservación física


Todas las imágenes son publicada con su correspondiente Dockerfile y cualquier usuario puede inspeccionarlas y mejorarlas. Las imágenes puede ser encontradas en DockerHub ¹² y GitHub ¹³.

¹²<https://hub.docker.com/u/dockerpedia/>

¹³<https://github.com/dockerpedia>



(a) Resultados originales entregados por el Information Sciences Institute



(b) Resultados reproducidos por nuestra propuesta

Figura 5.10: Los resultados obtenidos con el nuevo ambiente son iguales

Resource	Digital Ocean	Google Compute	Local
RAM (GB)	8	8	4
Disk (GB)	100	100	70
CPU (GHz)	2.0	2.5	2.8
CPU (Cores)	4	2	4
CPU (Arch)	64	64	64
OS	Centos 7	Debian 9	Fedora 27

Tabla 5.1: Image appliances characteristics.

Para evaluar la conservación física se utiliza tres proveedores diferentes: DigitalOcean, Google Cloud y un local. La figura de 5.1 presenta una descripción de las características de los ambientes

El ambiente debe tener instalado Docker, cada imagen en su manifiesto describe la versión de Docker con cuál fue construida. Sin embargo, Docker asegura idempotencia para los ambientes CentOS7, Debian 10/9/8/7.7, Fedora 26/27/28, Ubuntu 14.04/16.06/18.04, Windows 10, macOS El Capitan 10.11 o nuevas versiones. El proceso de instalación puede ser encontrado en la documentación oficial ¹⁴.

Cada imagen de Docker tiene archivo README con las instrucciones para correr el experimento. Las figuras 5.1 5.2 y 5.3 muestran los pasos necesarios para correr el experimento computacional.

El primer paso es correr el experimento y descargar la imagen:

Listing 5.1: Descargar y correr la imagen disponible en DockerHub mosorio/pegasus_workflow_images:soykb

```
docker run -d --rm -it --name soybean \
  mosorio/pegasus_workflow_images:soykb
```

Luego, el usuario debe entrar al container. El usuario puede confirmar que se encuentra dentro del container por el cambio de símbolo de la terminal (prompt).

Listing 5.2: Entrar al ambiente computacional utilizando bash

```
root@docker-instance:~# docker exec \
  -ti -u workflow:workflow soybean bash
workflow@a0f861e6fbc4:~
```

¹⁴<https://docs.docker.com/install/>

Finalmente, correr el workflow.

Listing 5.3: Run the workflow

```
workflow@a0f861e6fbc4 :~/soykb \  
./workflow-generator --exec-env distributed
```

Para evaluar si las imágenes Docker son livianas y almacenables, se construyó dos imágenes, una utilizando Docker y otra utilizando máquinas virtuales. La imagen de Docker se construyó bajo nuestro enfoque y la imagen de la máquina virtual basada en el trabajo de [6]. Luego se compara el uso de disco de ambas.

5.3. Conservación lógica

A través de las anotaciones realizadas, se busca describir los ambientes computacionales en forma automática, comparar las diferencias entre dos ambientes y construir un ambiente computacional similar que permita reproducir la ejecución del workflow.

Para ello, se anota de automática los workflows con nuestra herramienta, las anotaciones están agrupadas por: pasos de construcción y componentes de software.

Para evaluar la calidad de las anotaciones se utilizan dos experimentos.

- Reproducir el ambiente utilizando los pasos de construcción representados por DeploymentPlan.
- Detectar las similitudes y diferencias entre dos ambientes computacionales.

Para obtener las anotaciones, se propone e implementa usar Clair y construir un sistema de anotador. La figura 5.11 muestra los pasos principales del sistema.

1. El investigador pregunta sobre la información de una imagen al sistema anotador. El sistema anotador se encuentra escrito en GoLang y disponible en nuestro repositorio.
2. El sistema anotador pregunta a Clair sobre software y sus vulnerabilidades de la imagen. El sistema de Clair es una versión propia que puede detectar componentes de software instalado por Conda.
3. Para obtener los pasos de construcción, etiquetas, arquitectura y más información. El anotador obtiene el manifiesto de la imagen desde DockerHub

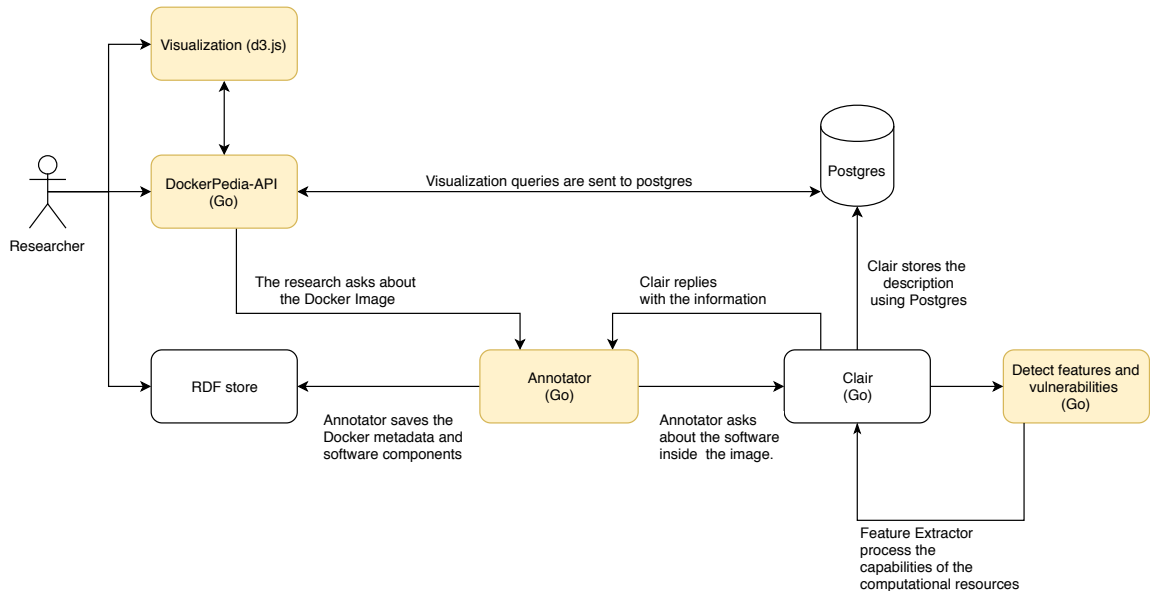


Figura 5.11: El sistema anotador permite recibir la información de la imagen, consultar los componentes de software a nuestra versión de Clair, obtener metadatos desde el manifiesto y almacenar la información en forma de triples en Apache Jena.

4. El sistema anotador guarda la información usando RDF y ontología propuesta.

Para reproducir el entorno, el sistema obtiene el repositorio asociado a la imagen y construir la nueva imagen. La URL del repositorio y el cambio asociado (representado por un VCS commit) se pueden obtener por dos métodos: consultando nuestras anotaciones o usando un comando Docker. El listado 5.4 muestra las etiquetas de la imagen de flujo de trabajo SoyKB.

Listing 5.4: Inspect image annotations

```

root@docker-instance:~# docker inspect \
  --format='{{json .Config.Labels}}' \
  dockerpedia/soykb:latest

```

La figura 5.5 muestra algunas de las etiquetas de la imagen basado en *Open Container Initiative*. Y todas las imágenes disponibles en nuestros repositorios presentan esas etiquetas.

Listing 5.5: Inspect image annotations

```

1 {

```

```

2 "maintainer": "Maximiliano Osorio <mosorio@inf.utfsm.cl>"
  ,
3 "org.label-schema.build-date": "2018-11-10T21:11:28Z",
4 "org.label-schema.name": "Soybean Knowledge Base",
5 "org.label-schema.schema-version": "1.0",
6 "org.label-schema.url": "http://www.soykb.org/",
7 "org.label-schema.vcs-ref": "15955b0",
8 "org.label-schema.vcs-url": "https://github.com/
  dockerpedia/soykb",
9 "org.label-schema.vendor": "DockerPedia",
10 "org.label-schema.version": "1.0"
11 }

```

Para evaluar si los entornos son similares, comparamos ambas imágenes utilizando el lenguaje de consulta SPARQL 1.1. El experimento fue un caso real en el que una imagen podía ejecutar el flujo de trabajo y la otra no. La figura 5.7 muestra la consulta para identificar los diferentes componentes de software entre dos imágenes.

Listing 5.6: ¿Cuáles son los diferentes componentes entre dos imágenes?

```

SELECT * WHERE {
  pegasus_workflow_images %3Alatest
  vocab:containsSoftware ?p .
MINUS{
  pegasus_workflow_images %3Apegasus-4.8.5
  vocab:containsSoftware ?p
}
}

```

Listing 5.7: ¿Cuáles son los componentes que comparten entre dos imágenes?

```

SELECT * WHERE {
  pegasus_workflow_images %3Alatest
  vocab:containsSoftware ?p .
  pegasus_workflow_images %3Apegasus-4.8.5
  vocab:containsSoftware ?p

```

5.4. Resultados y discusión

Se logró ejecutar los workflows utilizando imágenes Docker sobre sus plataformas correspondientes. Todas las ejecuciones se compararon con la imagen VM predefinida, donde ya existía un entorno de ejecución. Los resultados muestran que los ambientes de ejecución de contenedores son capaces de ejecutar completamente sus workflow relacionados. Se comprobó que no sólo los workflows se ejecutan con éxito, sino también que los resultados son correctos y equivalentes a través de los datos de salida producidos.

Por otra parte, los resultados experimentales muestran que nuestra propuesta puede detectar automáticamente los componentes del software, las vulnerabilidades relacionadas, los pasos de construcción y los metadatos específicos de los experimentos científicos en forma de imágenes Docker. Además, los resultados muestran que es posible extender Clair para anotar a otros gestores de paquetes.

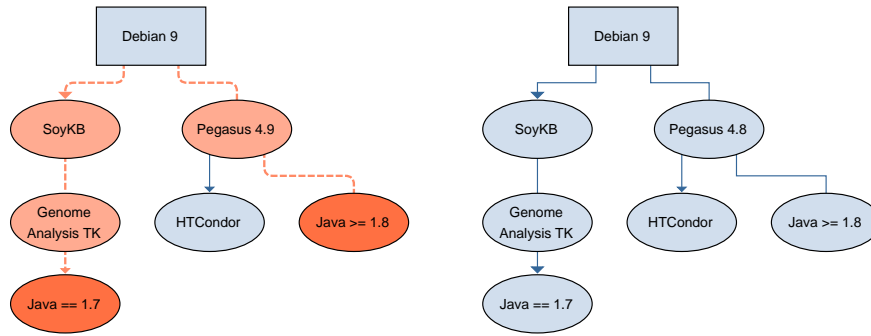
Las anotaciones generadas por nuestro enfoque permiten comparar los componentes de software entre dos o más entornos. Esta función se puede utilizar como herramienta de depuración cuando un entorno reproducido no funciona. Por ejemplo, en agosto de 2018, se construyó la imagen del workflow SoyKB, y se pudo ejecutar el flujo de trabajo con éxito. Sin embargo, se reconstruyó una nueva imagen en noviembre con el mismo DeploymentPlan y no se pudo ejecutar el workflow con éxito.

Se utilizó las anotaciones de los componentes de software dentro de ambas imágenes. Y se encontró las siguientes diferencias:

- Agosto: Pegasus 4.8 y Java 1.7
- Noviembre: Pegasus 4.9 y Java 1.8

Luego se analizó el código y la documentación de SoyKB y las dependencias de Pegasus 4.9. Como resultado, se obtuvo las gráficas de dependencia mostradas en la figura 5.12a. Los gráficos de dependencia muestran que el paquete Pegasus 4.9 y SoyKB no son compatibles debido a sus requerimientos de versión Java.

Y construyó una nueva imagen instalando Pegasus 4.8, y se obtuvo los gráficos de dependencia que se muestran en la figura 5.12b. Aquí, el gráfico no tiene un conflicto y se



(a) Dependencies graph Pegasus 4.9 and SoyKB (b) Dependencies graph Pegasus 4.8 and SoyKB

Figura 5.12: The orange nodes are the differences between the images

Enfoque	Pegasus (MB)	dispel4py (MB)
Virtualization	1929	3509
Container	690	2500

Tabla 5.2: Uso de disco de las imágenes pegasus y dispel4py utilizando máquinas virtuales y containers

pudo ejecutar el workflow con éxito.

La nueva imagen fue nombrada como: `pegasus_workflow_images:4.8.5`

La razón principal de los trabajos anteriores para evitar la conservación física era la gran demanda de almacenamiento de máquinas virtuales. Los resultados de la comparación del uso del disco muestran que hay una disminución del 64,2 % para la imagen Pegasus y del 41,5 % para la dispel4py. La tabla 5.2 muestra la diferencia para el sistema de flujo de trabajo Pegasus y dispel4py.

Capítulo 6

Conclusiones y trabajo futuro

6.1. Main 1

m at, molestie in quam. Aenean rhoncus vehicula hendrerit.

Bibliografía

- [1] K. A. Baggerly and K. R. Coombes, “Deriving chemosensitivity from cell lines: Forensic bioinformatics and reproducible research in high-throughput biology,” *The Annals of Applied Statistics*, pp. 1309–1334, 2009.
- [2] J. P. Ioannidis, D. B. Allison, C. A. Ball, I. Coulibaly, X. Cui, A. C. Culhane, M. Falchi, C. Furlanello, L. Game, G. Jurman, *et al.*, “Repeatability of published microarray gene expression analyses,” *Nature genetics*, vol. 41, no. 2, p. 149, 2009.
- [3] O. S. Collaboration *et al.*, “Estimating the reproducibility of psychological science,” *Science*, vol. 349, no. 6251, p. aac4716, 2015.
- [4] V. C. Stodden, “Reproducible research: Addressing the need for data and code sharing in computational science,” *Computing in science & engineering*, vol. 12, no. 5, pp. 8–12, 2010.
- [5] D. Garijo, S. Kinnings, L. Xie, L. Xie, Y. Zhang, P. E. Bourne, and Y. Gil, “Quantifying reproducibility in computational biology: the case of the tuberculosis drugome,” *PloS one*, vol. 8, no. 11, p. e80278, 2013.
- [6] I. Santana-Perez, R. F. da Silva, M. Rynge, E. Deelman, M. S. Pérez-Hernández, and O. Corcho, “Reproducibility of execution environments in computational science using semantics and clouds,” *Future Generation Computer Systems*, vol. 67, pp. 354–367, 2017.
- [7] A. Dappert, S. Peyrard, C. C. Chou, and J. Delve, “Describing and preserving digital object environments,” *New Review of Information Networking*, vol. 18, no. 2, pp. 106–173, 2013.

- [8] T. Craddock, P. Lord, C. Harwood, and A. Wipat, “E-science tools for the genomic scale characterisation of bacterial secreted proteins,” in *All hands meeting*, pp. 788–795, 2006.
- [9] D. Blankenberg, G. V. Kuster, N. Coraor, G. Ananda, R. Lazarus, M. Mangan, A. Nekrutenko, and J. Taylor, “Galaxy: a web-based genome analysis tool for experimentalists,” *Current protocols in molecular biology*, pp. 19–10, 2010.
- [10] B. Giardine, C. Riemer, R. C. Hardison, R. Burhans, L. Elnitski, P. Shah, Y. Zhang, D. Blankenberg, I. Albert, J. Taylor, *et al.*, “Galaxy: a platform for interactive large-scale genome analysis,” *Genome research*, vol. 15, no. 10, pp. 1451–1455, 2005.
- [11] E. Deelman, J. Blythe, Y. Gil, C. Kesselman, G. Mehta, S. Patil, M.-H. Su, K. Vahi, and M. Livny, “Pegasus: Mapping scientific workflows onto the grid,” in *Grid Computing*, pp. 11–20, Springer, 2004.
- [12] J. Goecks, A. Nekrutenko, and J. Taylor, “Galaxy: a comprehensive approach for supporting accessible, reproducible, and transparent computational research in the life sciences,” *Genome biology*, vol. 11, no. 8, p. R86, 2010.
- [13] T. M. Oinn, M. Addis, J. Ferris, D. Marvin, M. Senger, R. M. Greenwood, T. Carver, K. Glover, M. R. Pocock, A. Wipat, and P. Li, “Taverna: a tool for the composition and enactment of bioinformatics workflows,” *Bioinformatics*, vol. 20, no. 17, pp. 3045–3054, 2004.
- [14] Y. Gil, V. Ratnakar, J. Kim, P. A. González-Calero, P. T. Groth, J. Moody, and E. Deelman, “Wings: Intelligent workflow-based design of computational experiments,” *IEEE Intelligent Systems*, vol. 26, no. 1, pp. 62–72, 2011.
- [15] R. Filgueira, A. Krause, M. P. Atkinson, I. A. Klampanos, A. Spinuso, and S. Sanchez-Exposito, “dispel4py: An agile framework for data-intensive escience,” in *11th IEEE International Conference on e-Science, e-Science 2015, Munich, Germany, August 31 - September 4, 2015*, pp. 454–464, IEEE Computer Society, 2015.
- [16] J. Zhao, J. M. Gómez-Pérez, K. Belhajjame, G. Klyne, E. García-Cuesta, A. Garrido, K. M. Hettne, M. Roos, D. D. Roure, and C. A. Goble, “Why workflows break - understanding and combating decay in taverna workflows,” in *8th IEEE International*

Conference on E-Science, e-Science 2012, Chicago, IL, USA, October 8-12, 2012, pp. 1–9, IEEE Computer Society, 2012.

- [17] B. Matthews, E. Conway, J. Woodcock, C. Jones, J. Bicarregui, and A. Shaon, “Towards a methodology for software preservation,” in *Proceedings of the 6th International Conference on Digital Preservation, iPRES 2009, San Francisco, CA, USA, October 5-6, 2009*, 2009.
- [18] G. R. Brammer, R. W. Crosby, S. Matthews, and T. L. Williams, “Paper mâché: Creating dynamic reproducible science,” in *Proceedings of the International Conference on Computational Science, ICCS 2011, Nanyang Technological University, Singapore, 1-3 June, 2011* (M. Sato, S. Matsuoka, P. M. A. Slood, G. D. van Albada, and J. J. Dongarra, eds.), vol. 4 of *Procedia Computer Science*, pp. 658–667, Elsevier, 2011.
- [19] P. Buncic, C. A. Sanchez, J. Blomer, L. Franco, A. Harutyunian, P. Mato, and Y. Yao, “Cernvm—a virtual software appliance for lhc applications,” in *Journal of Physics: Conference Series*, vol. 219, p. 042003, IOP Publishing, 2010.
- [20] F. S. Chirigati, D. E. Shasha, and J. Freire, “Reprozip: Using provenance to support computational reproducibility,” in *5th Workshop on the Theory and Practice of Provenance, TaPP’13, Lombard, IL, USA, April 2-3, 2013* (A. Meliou and V. Tannen, eds.), USENIX Association, 2013.
- [21] E. Deelman, K. Vahi, G. Juve, M. Rynge, S. Callaghan, P. Maechling, R. Mayani, W. Chen, R. F. da Silva, M. Livny, and R. K. Wenger, “Pegasus, a workflow management system for science automation,” *Future Generation Comp. Syst.*, vol. 46, pp. 17–35, 2015.
- [22] F. da Veiga Leprevost, B. A. Grüning, S. Aflitos, H. L. Röst, J. Uszkoreit, H. Barsnes, M. Vaudel, P. Moreno, L. Gatto, J. Weber, M. Bai, R. C. Jimenez, T. Sachsenberg, J. Pfeuffer, R. V. Alvarez, J. Griss, A. I. Nesvizhskii, and Y. Pérez-Riverol, “Biocontainers: an open-source and community-driven framework for software standardization,” *Bioinformatics*, vol. 33, no. 16, pp. 2580–2582, 2017.
- [23] B. K. Beaulieu-Jones and C. S. Greene, “Reproducibility of computational workflows is automated using continuous analysis,” *Nature biotechnology*, vol. 35, no. 4, p. 342, 2017.

- [24] C. Boettiger, “An introduction to docker for reproducible research,” *SIGOPS Oper. Syst. Rev.*, vol. 49, pp. 71–79, Jan. 2015.
- [25] M. E. Aranguren and M. D. Wilkinson, “Enhanced reproducibility of sadi web service workflows with galaxy and docker,” *GigaScience*, vol. 4, no. 1, p. 59, 2015.
- [26] M. Osorio, C. B. Aranda, and H. Vargas, “Reproducibility of computational environments for scientific experiments using container-based virtualization,” in *Proceedings of the Second Workshop on Enabling Open Semantic Science co-located with 17th International Semantic Web Conference, SemSci@ISWC 2018, Monterey, California, USA, October 8-12th, 2018*. (D. Garijo, N. Villanueva-Rosales, T. Kuhn, T. Kauppinen, and M. Dumontier, eds.), vol. 2184 of *CEUR Workshop Proceedings*, pp. 43–51, CEUR-WS.org, 2018.
- [27] R. Shu, X. Gu, and W. Enck, “A Study of Security Vulnerabilities on Docker Hub,” in *Proceedings of the Seventh ACM on Conference on Data and Application Security and Privacy, CODASPY ’17*, (New York, NY, USA), pp. 269–280, ACM, 2017.
- [28] D. Huo, J. Nabrzyski, and C. Vardeman, “Smart container: an ontology towards conceptualizing docker,” in *International Semantic Web Conference (Posters & Demos)*, 2015.
- [29] A. Gangemi, N. Guarino, C. Masolo, A. Oltramari, and L. Schneider, “Sweetening ontologies with dolce,” in *International Conference on Knowledge Engineering and Knowledge Management*, pp. 166–181, Springer, 2002.
- [30] R. Tommasini, B. De Meester, P. Heyvaert, R. Verborgh, E. Mannens, and E. Della Valle, “Representing dockerfiles in RDF,” in *ISWC2017, the 16e International Semantic Web Conference*, vol. 1931, pp. 1–4, 2017.
- [31] M. Osorio, C. B. Aranda, and H. Vargas, “Dockerpedia: a knowledge graph of docker images,” in *Proceedings of the ISWC 2018 Posters & Demonstrations, Industry and Blue Sky Ideas Tracks co-located with 17th International Semantic Web Conference (ISWC 2018), Monterey, USA, October 8th - 12th, 2018.*, 2018.
- [32] T. Joshi, K. Patil, M. R. Fitzpatrick, L. D. Franklin, Q. Yao, J. R. Cook, Z. Wang, M. Libault, L. Brechenmacher, B. Valliyodan, *et al.*, “Soybean knowledge base

(soykb): a web resource for soybean translational genomics,” in *BMC genomics*, vol. 13, p. S15, BioMed Central, 2012.